



Alma Mater Studiorum-Università di Bologna
Scuola di Ingegneria

Numeri reali: rappresentazione, errori di calcolo, conseguenze

Corso di Laurea in Ingegneria Informatica
Anno accademico 2023/2024

Prof. ENRICO DENTI

Dipartimento di Informatica – Scienza e Ingegneria (DISI)



NUMERI REALI: ILLUSIONE OTTICA ?

- Secondo l'uomo della strada, un calcolatore *"non sbaglia mai i calcoli"*
- In realtà, con i numeri reali non è vero:
 - il calcolatore sbaglia i calcoli praticamente sempre, ma in modo *controllato* e *prevedibile*
 - la sensazione che non sia così è dovuta all' *illusione ottica* delle *funzioni di I/O*, che gestiscono lettura e scrittura di valori reali in modo da "non spaventare" l'utente finale
 - ...ma opportuni esperimenti possono facilmente rivelarlo ☺
- Un ingegnere deve conoscere la verità
 - per comprendere cosa accade *davvero*
 - per poter prendere eventuali *contromisure*



ESPERIMENTO

```
public static void test1() {  
    double val1 = 0.1;           // sembra 0.1 .. ma non lo è !  
    double val2 = 0.3;           // sembra 0.3 .. ma non lo è !  
  
    System.out.println(val1);    // stampa 0.1 .. ma è un'illusione !  
    System.out.println(val2);    // stampa 0.3 .. ma è un'illusione !  
  
    // ... e infatti, il triplo di val1 non è val2 !!!  
  
    double d = val1 + val1 + val1; // non è il triplo di val1...  
    if (d != val2) { System.out.print("ERRORE di ");  
        System.out.println(d - val2); } // differenza di 5.5E-17  
}
```

Java

```
val1 = 0.1  
val2 = 0.3  
ERRORE di 5.551115123125783E-17
```



ASTRAZIONE vs REALTÀ

- I numeri reali sono **un'astrazione** matematica
- Il **modello concreto** la approssima soltanto
 - **MOTIVO:** un modello reale non può ospitare infinite cifre, perché nessun dato può essere lungo "infiniti bit"
 - in matematica ce la si cava perché *spesso si trattano i valori in forma simbolica, senza fare calcoli*
 - MA un linguaggio di programmazione imperativo non ha tale capacità: "svolge i calcoli"... e ***nel farlo introduce errori***
- Di conseguenza:
 - i singoli valori sono tipicamente *errati* in una certa misura
 - effettuando operazioni, facilmente *gli errori si accumulano*
 - ciò può portare a risultati errati o perfino assurdi

L'ASTRAZIONE NUMERO REALE

- Un numero reale *può non essere finitamente rappresentabile* come stringa di simboli
 - in nessuna base: numeri irrazionali (π , e , ...)
 - in alcune basi: numeri razionali *periodici*
- In effetti, il fatto che la rappresentazione di un numero *razionale* sia periodica o meno *non dipende dal numero in sé*, ma solo dalla *base di rappresentazione* scelta per rappresentarlo
- **OGNI numero razionale è periodico in certe basi e non in altre:** è solo la nostra abitudine a considerare solo la base 10 a far pensare che certi numeri siano "più fortunati" di altri..

*Dunque, da cosa dipende esattamente
il "destino" di un numero?*



NUMERI REALI .. PERIODICI?

- La rappresentazione di un numero reale è *periodica* se **non tutti i fattori primi del denominatore della forma fratta sono presenti nella base di rappresentazione**
 - in base 10 sono finitamente rappresentabili *tutti e soli quei valori costruibili con 1/2 e 1/5, combinati/elevati a qualunque esponente*
 - 0.02 non è periodico perché generato da $1/50 = (1/2)(1/5)^2 = 2/100$
 - 0.(3) è periodico perché 1/3 non è costruibile finitamente con 1/2 e 1/5:
infatti, $\frac{1}{3} = \frac{3}{9} = \frac{3}{10} \sum_{k \geq 0} \left(\frac{1}{10}\right)^k$ che è una somma di infiniti termini:
$$\frac{1}{3} = \frac{3}{10} + \frac{3}{100} + \frac{3}{1000} + \frac{3}{10000} + \dots = 0,3333 \dots$$
 - in particolare, quindi, la rappresentazione ***non è mai periodica nella base B del denominatore*** della forma fratta:
 - $1/3 = (0.333333333333\dots)_{10} = (0.1)_3$
 - $8/7 = (1.142857142857\dots)_{10} = (1.1)_7$



NUMERI REALI IN DIVERSE BASI

- A causa di ciò:
 - se la rappresentazione di un numero razionale è periodica in base B , sarà *periodica anche in base $B' = B/k$* , dato che perdendo fattori primi la situazione può solo peggiorare
 - viceversa, aumentando la quantità di fattori primi ($B' = B \cdot k$) la situazione può *migliorare* (grazie al nuovo fattore primo k) e dunque un numero periodico potrebbe divenire finitamente rappresentabile
 - ovviamente, *ciò non accadrà mai se $B' = B^n$* poiché in tal caso i fattori primi resteranno gli stessi
- In pratica:
 - un numero la cui rappresentazione sia periodica in base 10 sarà sicuramente periodico anche in base 2 o in base 5 (perde fattori..)
 - al contrario, un numero periodico in base 2 può essere o non essere periodico in base 10, ma lo è certamente in base 4, 8, 16, ...



DALL'ASTRAZIONE AL MODELLO

- **L'astrazione** numero reale può implicare una rappresentazione infinita di cifre, ma in matematica non è un problema perché *non si scrivono!*
 - si adottano rappresentazioni simboliche ($4/3$, π , e), che in quanto tali sono sempre *esatte e finite*
- Il **modello concreto** invece deve basarsi sulla *sequenza di cifre*, che tipicamente è *infinita*
 - non c'è $4/3$: c'è $1.3333\dots$
 - non c'è π : c'è $3.1415\dots$

Come definire il modello concreto di numero reale in modo efficiente?



NUMERI REALI: MANTISSA E RESTO

- Fissata una base B , è sempre possibile scrivere un numero reale V come *somma di due contributi*:
 - una **MANTISSA** di n cifre
 - il corrispondente **RESTO**

$$V \equiv M + R$$

- Ad esempio, se $V=31.4357$, in base $B=10$:
 - con $n=3$ cifre: $V = 31.4 + 0.0357$
 - con $n=4$ cifre: $V = 31.43 + 0.0057$
 - con $n=5$ cifre: $V = 31.435 + 0.0007$



MANTISSA E RESTO: PROBLEMI

- Così, però, *la mantissa potrebbe risultare molto grande, molto piccola, o impossibile da esprimere su n cifre*, in base all'ordine di grandezza di V :
- Ad esempio, se $V = .014357$, in base $B=10$:
 - con $n=2$ cifre: $V = .01 + .004357$
 - con $n=3$ cifre: $V = .014 + .000357$
 - con $n=4$ cifre: $V = .0143 + .000057$
 - ma attenzione:
con $n=1$ cifra: $V = .0 + .14357$
- Se invece $V = 1567.35$, in base $B=10$:
 - con $n=3$ cifre: $V = 156? + ???$



MANTISSA E RESTO: RIDEFINIZIONE

- Per evitare questi assurdi, si conviene di scrivere la *mantissa* in forma *esponenziale*:

$$M \equiv m * B^{\text{esp}}$$

da cui:

$$V \equiv m * B^{\text{esp}} + R$$

scegliendo *esp* in modo che la mantissa risulti *normalizzata*,
ossia compresa fra 0 e 1 (escluso):

$$1/B \leq m < 1$$

- Per analogia, spesso si esprime anche il resto *R* in forma esponenziale, ponendo $R = r * B^{\text{esp}-n}$
così, anche per *r* vale l'analoga relazione $1/B \leq r < 1$



MANTISSA E RESTO NORMALIZZATI

- Se $V=0.014357$, in base $B=10$, risulta **esp = -1**:

- con $n=2$ cifre: $V = .14 * 10^{-1} + .000357$
- con $n=3$ cifre: $V = .143 * 10^{-1} + .000057$
- con $n=4$ cifre: $V = .1435 * 10^{-1} + .000007$

ovvero, normalizzando anche il resto ($\text{esp}-n = -4$):

- con $n=3$ cifre: $V = .143 * 10^{-1} + .57 * 10^{-4}$

- Se invece $V=1567.35$, in base $B=10$, risulta **esp = +4**:

- con $n=3$ cifre: $V = .156 * 10^{+4} + 7.35$
- con $n=4$ cifre: $V = .1567 * 10^{+4} + .35$

ovvero, normalizzando anche il resto ($\text{esp}-n = 1$):

- con $n=3$ cifre: $V = .156 * 10^{+4} + .735 * 10^1$
- con $n=4$ cifre: $V = .1567 * 10^{+4} + .35 * 10^0$



NUMERI REALI: IL VINCOLO

- Un numero reale ha spesso una rappresentazione infinita in una data base, ma *rappresentare infinite cifre è impossibile*
- Perciò, assumiamo come **rappresentazione approssimata** del numero V il solo contributo **$m * B^{\text{esp}}$**

$$V \approx m * B^{\text{esp}}$$

- Il resto si trascura → **Errore di *troncamento***



SCELTE OPERATIVE

- In pratica dobbiamo stabilire:
 - il numero **N** di **cifre binarie (bit)** per la mantissa
 - il numero **P** di **cifre binarie (bit)** per l'esponente
 - la codifica da adottare per l'esponente
 - come rappresentare *il segno* del numero
- Osservazione: nel caso $B=2$, $1/2 \leq m < 1$
ossia *il primo bit dopo la virgola è sempre 1*
- Quindi, *si può evitare di scriverlo esplicitamente*,
perché *un bit prefissato non porta informazione*
- **N cifre binarie** si rappresentano con soli **N-1 bit**

LE SPECIFICHE IEEE-754

	float	double
bit di segno	1 bit (il più significativo) 0 = + 1 = -	
mantissa	N = 24 bit rappresentata con 23 bit , dal meno al più significativo	N = 53 bit rappresentata con 52 bit , dal meno al più significativo
esponente	P = 8 bit	P = 11 bit
rappresent. esponente	rappresentazione con eccesso 2^P-1-2	
	eccesso 126 • da 127 a 254 $\leftrightarrow$ esp. [1..128] • da 1 a 125 $\leftrightarrow$ esp. [-125..-1] • 0 e 255 $\leftrightarrow$ <i>casi speciali</i>	eccesso 1022 • da 1023 a 2046 $\leftrightarrow$ esp. [1..1024] • da 1 a 1021 $\leftrightarrow$ esp. [-1021..-1] • 0 e 2047 $\leftrightarrow$ <i>casi speciali</i>
valori rap- presentabili	$\text{MIN} = .1 * 2^{1-126}$ $\text{MAX} = .1111..111 * 2^{254-126}$ $\text{RANGE} \approx [2^{-126} \dots 2^{128}]$ $[1.2 * 10^{-38} \dots 3.4 * 10^{38}]$	$\text{MIN} = .1 * 2^{1-1022}$ $\text{MAX} = .1111..111 * 2^{2046-1022}$ $\text{RANGE} \approx [2^{-1022} \dots 2^{1024}]$ $[1.3 * 10^{-308} \dots 0.7 * 10^{308}]$

LE SPECIFICHE IEEE-754

Come mai questa scelta?

Perché così è immediato confrontare due valori!

Basta controllare bit a bit gli esponenti!

mantissa	N = 24 bit rappresentata con 23 bit , dal meno al più significativo	N = 53 bit rappresentata con 52 bit , dal meno al più significativo
esponente	P = 8 bit	P = 11 bit
rappresent. esponente	rappresentazione con eccesso $2^{P-1}-2$	
	eccesso 126 - da 127 a 254 $\leftrightarrow$ esp. [1..128] - da 1 a 125 $\leftrightarrow$ esp. [-125..-1] 0 e 255 $\leftrightarrow$ <i>casi speciali</i>	eccesso 1022 - da 1023 a 2046 $\leftrightarrow$ esp. [1..1024] - da 1 a 1021 $\leftrightarrow$ esp. [-1021..-1] 0 e 2047 $\leftrightarrow$ <i>casi speciali</i>
valori rappresentabili	$\text{MIN} = .1 * 2^{1-126}$ $\text{MAX} = .1111..111 * 2^{254-126}$ $\text{RANGE} \approx [2^{-126} \dots 2^{128}]$ $[1.2 * 10^{-38} \dots 3.4 * 10^{38}]$	$\text{MIN} = .1 * 2^{1-1022}$ $\text{MAX} = .1111..111 * 2^{2046-1022}$ $\text{RANGE} \approx [2^{-1022} \dots 2^{1024}]$ $[1.3 * 10^{-308} \dots 0.7 * 10^{308}]$



LE SPECIFICHE IEEE-754

- Casi speciali ($\text{esp}_{\text{MAX}}=255$ per i float, 2047 per i double):

$\text{esp}=0$, $m=0$ rappresenta 0.0

$\text{esp}=\text{esp}_{\text{MAX}}$ $m=0$ rappresenta $\pm \infty$

$\text{esp}=\text{esp}_{\text{MAX}}$ $m \neq 0$ rappresenta NaN

$\text{esp}=0$ $m \neq 0$ rappresenta *valori non normalizzati*

dove

- NaN (*Not a Number*) è il risultato di operazioni *indeterminate* o *impossibili*:

$$0 / 0$$

$$0 * \infty$$

$$\infty - \infty$$

$$\infty / \infty$$

- i valori non normalizzati consentono di rappresentare numeri "più piccoli del minimo valore normalizzato possibile", ampliando così il range di valori rappresentabili a parità di costo.



NUMERI REALI: CIFRE SIGNIFICATIVE

- Assumendo $V \approx m * B^{\text{esp}}$, si trascura il resto $r * B^{\text{esp}-N}$
- Poiché nella forma normalizzata $r < 1$, l'errore in termini assoluti vale:

$$E_{\text{assoluto}} \leq B^{\text{esp}-N}$$

- Tuttavia, esso non è molto significativo *in sé*: lo è molto di più se *rapportato al valore del numero*

$$E_{\text{relativo}} \leq B^{\text{esp}-N} / (m * B^{\text{esp}})$$

- da cui, poiché $1/B \leq m < 1$,

$$E_{\text{relativo}} \leq B^{\text{esp}-N} / B^{\text{esp}-1} = B^{1-N}$$



NUMERI REALI: CIFRE SIGNIFICATIVE

- L'errore relativo $E_{\text{relativo}} \leq B^{1-N}$ permette di *stimare le cifre significative* di un numero in base ai bit della mantissa
- In un **float**, la mantissa ha **24 bit**
 - $E_{\text{relativo}} \leq 2^{-23} = 10^{-23 \cdot \log 2} = 10^{-7}$
 - ovvero, il numero ha circa **7-8 cifre decimali significative** (più facilmente 8, se si arrotonda anziché troncare)
- In un **double**, la mantissa ha **53 bit**
 - $E_{\text{relativo}} \leq 2^{-52} = 10^{-52 \cdot \log 2} = 10^{-16}$
 - ovvero, il numero ha circa **16-17 cifre decimali significative**

Per questo `println` stampa 8 cifre per i **float** e 16 cifre per i **double** 😊

```
jshell> System.out.println(1/3.0F)
0.33333334
jshell> System.out.println(1/3.0)
0.3333333333333333
```



NUMERI REALI: ESEMPIO 1

Rappresentazione come float di $V = 1.0$

- *rappr. normalizzata*: $V = 1.0_{10} = 0.1_2 * 2^1$
- *segno (1 bit)*: 0
- *mantissa (24 bit)*: .10000000 00000000 00000000
- *esponente (8 bit con eccesso 126)*
esp=1 $\rightarrow 126+1 = 127 \rightarrow$ 01111111

segno	esponente	mantissa normalizzata (23 bit, MSB escluso)
0	0111 1111	000 0000 0000 0000 0000 0000

in memoria:

byte 1	byte 2	byte 3	byte 4
0011 1111	1000 0000	0000 0000	0000 0000



NUMERI REALI: ESEMPIO 2

Rappresentazione come float di $V = 5.875$

- *rappr. normalizzata*: $V = 101.111_2 = .101111_2 * 2^3$
- *segno (1 bit)*: 0
- *mantissa (24 bit)*: .10111100 00000000 00000000
- *esponente (8 bit con eccesso 126)*
 $esp=3 \rightarrow 126+3 = 129 \rightarrow 10000001$

segno	esponente	mantissa normalizzata (23 bit, MSB escluso)
0	1000 0001	011 1100 0000 0000 0000 0000

in memoria:

byte 1	byte 2	byte 3	byte 4
01000000	1011 1100	0000 0000	0000 0000



NUMERI REALI: ESEMPIO 3

Rappresentazione come float di $V = -29.1875$

- *rappr. normalizzata*: $V = - .111010011_2 * 2^5$
- *segno (1 bit)*: **1**
- *mantissa (24 bit)*: **.11101001 10000000 00000000**
- *esponente (8 bit con eccesso 126)*
 $\text{esp}=5 \rightarrow 126+5 = 131 \rightarrow \mathbf{10000011}$

segno	esponente	mantissa normalizzata (23 bit, MSB escluso)
1	1000 0011	110 1001 1000 0000 0000 0000

in memoria:

byte 1	byte 2	byte 3	byte 4
1100 0001	1110 1001	1000 0000	0000 0000



NUMERI REALI: ESEMPIO 4

Rappresentazione come float di $V = 0.1_{10}$

- *rappr. normalizzata*: $V = .0(0011)_2$ periodico!
- *segno (1 bit)*: 0
- *mantissa (24 bit)*: .11001100 11001100 11001100
- *esponente (8 bit con eccesso 126)*
 $\text{esp} = -3 \rightarrow 126 - 3 = 123 \rightarrow 01111011$

segno	esponente	mantissa normalizzata (23 bit, MSB escluso)
0	0111 1011	100 1100 1100 1100 1100

in memoria:

byte 1	byte 2	byte 3	byte 4
0011 1101	1100 1100	1100 1100	1100 1100



NUMERI REALI: ESEMPIO 4

Rappresentazione come float

- *rappr. normalizzata*: $V = .0(0011$
- *segno (1 bit)*: 0
- *mantissa (24 bit)*: .11001100 11001100 11001101
- *esponente (8 bit con eccesso 126)*
 $esp = -3 \rightarrow 126 - 3 = 123 \rightarrow 01111011$

Errore di troncamento
o si tronca o si arrotonda
Di solito si arrotonda

segno	esponente	mantissa normalizzata (23 bit, MSB escluso)
0	0111 1011	100 1100 1100 1100 1101

in memoria:

byte 1	byte 2	byte 3	byte 4
0011 1101	1100 1100	1100 1100	1100 1101



NUMERI REALI: ESEMPIO 5

Rappresentazione come float di $V = 0.15_{10}$

- *rappr. normalizzata:* $V = .00(1001)_2$ periodico!
- *segno (1 bit):* 0
- *mantissa (24 bit):* .10011001 10011001 10011010
- *esponente (8 bit con eccesso 126)*
 $\text{esp} = -2 \rightarrow 126 - 2 = 124 \rightarrow 01111100$

segno	esponente	mantissa normalizzata (23 bit, MSB escluso)
0	0111 1100	001 1001 1001 1001 1001 1010

in memoria:

byte 1	byte 2	byte 3	byte 4
0011 1110	0001 1001	1001 1001	1001 1010



NUMERI REALI: ESEMPIO 6

Rappresentazione come float di $V = -1/3_{10}$

- *rappr. normalizzata:* $V = -(01)_2$ periodico!
- *segno (1 bit):* 1
- *mantissa (24 bit):* .10101010 10101010 10101011
- *esponente (8 bit con eccesso 126)*
 $\text{esp} = -1 \rightarrow 126 - 1 = 125 \rightarrow 01111101$

segno	esponente	mantissa normalizzata (23 bit, MSB escluso)
1	0111 1101	010 1010 1010 1010 1010 1011

in memoria:

byte 1	byte 2	byte 3	byte 4
1011 1110	1010 1010	1010 1010	1010 1011



ESPERIMENTI: SPIARE DENTRO JAVA

- Come verificare se quanto calcolato è esatto?
 - occorre un modo per "spiare" dentro la macchina virtuale del linguaggio (Java, C, Pascal, ...)
- In Java, la classe wrapper **Float** (risp. **Double**) fornisce la funzione **floatToIntBits** (risp. **doubleToLongBits**)
 - tale funzione "estrae" la rappresentazione di un **float** (risp. **double**) bit per bit e la pone in un **int** (risp. **long**) pronta per la stampa o altre elaborazioni.



ESEMPIO: SPIARE UN FLOAT in Java

Esempio di codice che "spia" un float `f`:

```
System.out.println("Numero float: " + f);  
int internalRep = Float.floatToIntBits(f);  
String binaryString =  
    Integer.toBinaryString(internalRep);  
// estetica: aggiunta di opportuni '0' davanti  
while (binaryString.length() < 32)  
    binaryString = "0" + binaryString;  
System.out.println(binaryString);
```

Stampa una stringa di 32 bit:

10111110101010101010101010101011



ESPERIMENTI: MIGLIORIE ESTETICHE

- Per renderla più leggibile per noi, può essere opportuno *separare le varie parti*:

1 01111101 01010101010101010101011

o magari, meglio:

1 01111101 0101010 10101010 10101011

Per farlo:

```
System.out.println(  
    binaryString.charAt(0) + " " +  
    binaryString.substring(1,9) + " " +  
    binaryString.substring(9,16) + " " +  
    binaryString.substring(16,24) + " " +  
    binaryString.substring(24,32) );
```

segno: 1 bit

esponente: 8 bit

mantissa:
7 + 8 + 8 bit



ESPERIMENTI: CODICE

```
public static void decodeFloat(float f) {  
    System.out.println("Numero float: " + f);  
    int internalRep = Float.floatToIntBits(f);  
    String binString = Integer.toBinString(internalRep);  
    while (binString.length() < 32) binString = '0' + binString;  
    System.out.println("Segno:      " + binString.charAt(0));  
    System.out.println("Esponente: "  
        + binString.substring(1,9) + " ("  
        + Integer.valueOf(binString.substring(1,9),2) + ")");  
    System.out.println("Mantissa:  "  
        + binString.substring(9,16) + " "  
        + binString.substring(16,24) + " "  
        + binString.substring(24,32));  
}
```



ESPERIMENTI CON FLOAT (1/2)

$V = 1.0$

- *segno* (1 bit): 0
- *esponente*: 01111111
- *mantissa* (24 bit): .10000000 00000000 00000000

```
Numero float: 1.0
Segno:      0
Esponente:  01111111 <127>
Mantissa:   00000000 00000000 00000000
```

$V = 5.875$

- *segno* (1 bit): 0
- *esponente*: 10000001
- *mantissa* (24 bit): .10111100 00000000 00000000

```
Numero float: 5.875
Segno:      0
Esponente:  10000001 <129>
Mantissa:   0111100 00000000 00000000
```

$V = -29.1875$

- *segno* (1 bit): 1
- *esponente*: 10000011
- *mantissa* (24 bit): .11101001 10000000 00000000

```
Numero float: -29.1875
Segno:      1
Esponente:  10000011 <131>
Mantissa:   11101001 10000000 00000000
```



ESPERIMENTI CON FLOAT (2/2)

$V = 0.1$

- *segno* (1 bit): 0
- *esponente*: 01111011
- *mantissa* (24 bit): .11001100 11001100 11001101 (arrotondata)

```
Numero float: 0.1
Segno:      0
Esponente:  01111011 <123>
Mantissa:   1001100 11001100 11001101
```

$V = 0.15$

- *segno* (1 bit): 0
- *esponente*: 01111100
- *mantissa* (24 bit): .10011001 10011001 10011010 (arrotondata)

```
Numero float: 0.15
Segno:      0
Esponente:  01111100 <124>
Mantissa:   0011001 10011001 10011010
```

$V = -1/3$

- *segno* (1 bit): 1
- *esponente*: 01111101
- *mantissa* (24 bit): .10101010 10101010 10101011 (arrotondata)

```
Numero float: -0.33333334
Segno:      1
Esponente:  01111101 <125>
Mantissa:   0101010 10101010 10101011
```



ESPERIMENTI CON DOUBLE

$V = 0.1$

- *segno* (1 bit): 0
- *esponente*: 01111111011
- *mantissa* (53 bit): .11001100 11001100 ...11010 (arrotondata)

```
Numero float: 0.1
Segno: 0
Esponente: 01111011 <123>
Mantissa: 1001100 11001100 11001101
```

```
Numero double: 0.1
Segno: 0
Esponente: 01111111011 <1019>
Mantissa: 1001100 11001100 11001100 11001100 11001100 11001100 11010
```

$V = -1/3$

- *segno* (1 bit): 1
- *esponente*: 01111111101
- *mantissa* (53 bit): .10101010 10101010 ...10101 (arrotond./troncata)

```
Numero float: -0.33333334
Segno: 1
Esponente: 01111101 <125>
Mantissa: 0101010 10101010 10101011
```

```
Numero double: -0.3333333333333333
Segno: 1
Esponente: 01111111101 <1021>
Mantissa: 0101010 10101010 10101010 10101010 10101010 10101010 10101
```

ESPERIMENTI ... MIXED!

$V = 0.1$ (valore `float` convertito in `double`)

- segno (1 bit): 0
- esponente: 01111111011
- mantissa (53 bit): . 11001100 11001100 11001101 00000000 ...

```
Numero float: 0.1
Segno: 0
Esponente: 01111011 (123)
Mantissa: 1001100 11001100 11001101
```

```
Numero double: 0.1
Segno: 0
Esponente: 01111111011 (1019)
Mantissa: 1001100 11001100 11001100 11001100 11001100 11001100 11010
```

```
Numero double: 0.10000000149011612
Segno: 0
Esponente: 01111111011 (1019)
Mantissa: 1001100 11001100 11001101 00000000 00000000 00000000 00000000
```

ATTENZIONE: poiché provengono da un float, le cifre oltre la sesta (settima) *non sono significative*

Bit tutti a zero, perché il valore originale, float, era rappresentato su soli 24 bit



OPERAZIONI & ERRORI

- Negli interi:
 - si possono creare errori nelle operazioni
 - MA *i singoli operandi* sono sempre *rappresentati esattamente* (entro il range corrispondente al numero di bit disponibili)
- Nei reali:
 - *gli operandi possono già essere affetti da errore prima ancora di iniziare le operazioni* a causa dell'impossibilità di rappresentare le infinite cifre dei numeri periodici e irrazionali
- È il famigerato *errore di troncamento*, che si manifesta *quando il numero di cifre disponibili è insufficiente* a rappresentare compiutamente il valore.



ERRORE DI TRONCAMENTO

- Si manifesta quando:
 - il numero è **periodico**
 - il numero **non è periodico** ma ha **troppe cifre**
 - il risultato di un'operazione, a causa un riporto, richiede comunque **troppe cifre** per essere rappresentato
- Esempi (mantissa di 8 bit, per semplicità)
 - $15.8_{10} = .1111110011001100... * 2^4$ (è 15.75)
 - $300.5_{10} = .1001011001_2 * 2^9$ (è 300)
 - $151_{10} + 160_{10} =$
 $= .10010111 * 2^8 + .10100000 * 2^8 =$
 $= .100110111 * 2^9$ (è 310)



OPERAZIONI FRA REALI & ERRORI

Oltre al troncamento, vi sono altri due sorgenti di errore

- **Errore di *incolonnamento***: è causato dalla *necessità di incolonnare i numeri* per poterli sommare o sottrarre
- **Errore di *cancellazione***: è la *conseguenza a valle* della presenza di errori di troncamento *a monte*, quando si sottraggono numeri simili fra loro
 - si chiama così perché, a causa del troncamento a monte, alcune cifre del risultato vengono “*virtualmente cancellate*”, ossia sono *inaffidabili*



ERRORE DI INCOLONNAMENTO

- L'errore di **incolonnamento** è dovuto al fatto che, per sommare/sottrarre due numeri, bisogna prima *incolonnarli*
 - se hanno *esponente diverso*, per incolonnarli bisogna per forza “*de-normalizzarne*” uno
 - per minimizzare il danno, si allinea quello di *valore assoluto minore* a quello di valore assoluto maggiore (che resta intonso)
 - ciò causa una *perdita di cifre significative* nel numero che viene “de-normalizzato”, a causa dello shift verso destra di tante posizioni quante quelle necessarie per incolonnarlo all'altro



ERRORE DI INCOLONNAMENTO

- Esempio: $96.5 + 1.75$
 - Ipotesi: mantissa di 8 bit (per semplicità)
 - $96.5_{10} = .11000001_2 * 2^7$ (senza errore)
 - $1.75_{10} = .11100000_2 * 2^1$ (senza errore)

- Somma:

$$\begin{array}{r} .11000001_2 * 2^7 + \\ .11\textcolor{red}{100000}_2 * 2^1 = \end{array}$$

Cifre condannate:
è l'errore di
incolonnamento

$$\begin{array}{r} .11000001_2 * 2^7 + \\ \textcolor{blue}{.000000}11_2 * 2^7 = \end{array}$$

$$.11000100_2 * 2^7$$

Il risultato è **98 anziché 98.25** a causa dello shift a destra di 6 posizioni nel secondo addendo, causato dall'incolonnamento.



ERRORE DI INCOLONNAMENTO: ESPERIMENTO

```
public static void test() {  
    double val1 = 12345.0; // numero di 5 cifre..  
    double val2 = 1e-13; // proprio al limite: 18 cifre  
    // errore di incolonnamento:  
    // val1 + val2 COINCIDE con val1 !  
    if (val1 + val2 == val1)  
        System.out.println("val1 + val2 == val1 !!");  
}
```

Con **val2=1e-12**, invece, ce la fa: siamo al limite!

val1 + val2 == val1 !!



ERRORI: ESPERIMENTO

```
public static void test1() {  
    double val1 = 0.1;           // sembra 0.1 .. ma non lo è !  
    double val2 = 0.3;           // sembra 0.3 .. ma non lo è !  
  
    System.out.println(val1);    // stampa 0.1 .. ma è un'illusione !  
    System.out.println(val2);    // stampa 0.3 .. ma è un'illusione !  
  
    // ... e infatti, il triplo di val1 non è val2 !!!  
  
    double d = val1 + val1 + val1; // non è il triplo di val1...  
  
    if (d != val2) { System.out.print("ERRORE di ");  
        System.out.println(d - val2); } // differenza di 5.5E-17  
}
```

```
val1 = 0.1  
val2 = 0.3  
ERRORE di 5.551115123125783E-17
```



ERRORE DI CANCELLAZIONE

- L'errore di **cancellazione** avviene quando *si sottraggono* due numeri «piuttosto vicini» fra loro
 - accade solo se almeno uno dei due operandi *all'inizio* era stato *troncato*, in quanto ciò gli ha «amputato» alcune cifre
 - la sottrazione di valori «piuttosto vicini» causa infatti *l'introduzione da destra di zeri* per normalizzare il risultato, *MA quegli zeri non sono significativi* appunto perché discendono dal troncamento iniziale
 - se l'operando non fosse stato troncato, ora quelle cifre entrerebbero in gioco e il risultato sarebbe diverso.



ERRORE DI CANCELLAZIONE

- Esempio: $15.8 - 15.5$
 - Ipotesi: mantissa di 8 bit (per semplicità)
 - $15.8_{10} = .11111100_2 * 2^4$ (con errore tronc.)
 - $15.5_{10} = .11111000_2 * 2^4$ (senza errore)

- Differenza:

$$.11111100_2 * 2^4 -$$

$$.11111000_2 * 2^4 =$$

Cifre cancellate:
è l'errore di cancellazione

$$.00000100_2 * 2^4 = .1000000_2 * 2^{-1}$$

Queste cifre sono 0 solo perché abbiamo troncato
il 15.8 all'inizio: avrebbero dovuto essere 11001



ERRORI: CONSEGUENZE

- A causa di questi errori, *la proprietà associativa può non essere più verificata*
- Esempio (mantissa di 8 bit, per semplicità)
 - $X = 0,75 \rightarrow .11000000 * 2^0$ (senza errori)
 - $Y = 65,6 \rightarrow .10000011 * 2^7$ (err. troncamento)
 - $Z = 64,0 \rightarrow .10000000 * 2^7$ (senza errori)
- Orrore:
 $(X + Y) - Z$ è diverso da $X + (Y - Z)$

ERRORI: CONSEGUENZE

$(X + Y) - Z$ è diverso da $X + (Y - Z)$

Primo caso: $(X + Y) - Z$	Secondo caso: $X + (Y - Z)$
<i>Prima operazione: $A = X + Y$</i> $ \begin{array}{r} .11000000 * 2^0 + \\ .10000011 * 2^7 = \\ \hline .00000001 * 2^7 + \quad (\text{err. incolonnamento}) \\ .10000011 * 2^7 = \\ \hline .10000100 * 2^7 \rightarrow A \end{array} $ <i>Seconda operazione: $R = A - Z$</i> $ \begin{array}{r} .10000100 * 2^7 - \\ .10000000 * 2^7 = \\ \hline .00000100 * 2^7 = \quad (\text{da rinormalizzare}) \\ .100???? * 2^2 = \quad (\text{errore cancellazione}) \\ \hline .10000000 * 2^2 \rightarrow R \end{array} $	<i>Prima operazione: $A = Y - Z$</i> $ \begin{array}{r} .10000011 * 2^7 - \\ .10000000 * 2^7 = \\ \hline .00000011 * 2^7 = \quad (\text{da rinormalizzare}) \\ .11???? * 2^1 = \quad (\text{errore cancellazione}) \\ \hline .11000000 * 2^1 \rightarrow A \end{array} $ <i>Seconda operazione: $R = X + A$</i> $ \begin{array}{r} .11000000 * 2^0 + \\ .11000000 * 2^1 = \\ \hline .01100000 * 2^1 + \quad (\text{err. incolonnamento}) \\ .11000000 * 2^1 = \\ \hline 1.00100000 * 2^1 \quad (\text{da rinormalizzare}) \\ .10010000 * 2^2 \rightarrow R \quad (\text{err. trunc. potenziale}) \end{array} $

$$R = .10000000 * 2^2$$

$$R = .100\mathbf{1}0000 * 2^2$$



ERRORE DI CANCELLAZIONE: ESEMPIO

- Teoricamente, $1/3 - 1/4 = 1/12$
- MA in realtà...

```
jshell> System.out.println(1/3.0-1/4.0)
0.083333333333333331

jshell> System.out.println(1/12.0)
0.083333333333333333

jshell> System.out.println(1/3F-1/4F)
0.08333334

jshell> System.out.println(1/12F)
0.083333336
```



ERRORE DI CANCELLAZIONE: CONTROESEMPIO

- L'unico caso in cui il problema *non* si manifesta è se *nessuno dei due operandi* è stato *inizialmente troncato*
 - ad esempio, $1/4 - 1/64 = 15/64$ è rappresentato esattamente:


```
jshell> System.out.println(1/4F-1/64F)
0.234375

jshell> System.out.println(1/4.0-1/64.0)
0.234375
```

- in questo caso la rappresentazione è esatta sia usando un float, sia usando un double


ACCUMULAZIONE DI ERRORI

- La presenza di *errori che si accumulano* può portare a *risultati assurdi*
- Esempio: *calcolo di π con l'algoritmo di Euclide*
 - una circonferenza di raggio 1 è lunga 2π
 - essa può essere approssimata *dall'interno* o *dall'esterno*
 - dall'interno, dal perimetro del poligono regolare di n lati *inscritto*
 - dall'esterno, dal perimetro del poligono regolare di n lati *circoscritto*
 - più è alto il numero N di lati del poligono, maggiore sarà la precisione del calcolo



ACCUMULAZIONE DI ERRORI

- Valgono le relazioni:
 - ℓ_n = lato del poligono di n lati *inscritto*
 - L_n = lato del poligono di n lati *circoscritto* = $2 \ell / \sqrt{4 - \ell^2}$





L'ALGORITMO IN JAVA (1/2)

```
import java.io.*;

public class PigrecoEuclide {

    public static void main(String[] args) {

        System.out.println("Calcolo di pigreco con FLOAT.");
        System.out.print("Precisione [1e-8] ? ");

        float eps = 1E-8F; // inizializz. richiesta da eccezione

        try{

            BufferedReader kbd = new BufferedReader(
                                new InputStreamReader(System.in));

            eps = Float.parseFloat(kbd.readLine());

        }
        catch(IOException e){

            System.err.println("Errore di input - Program exit");
            System.exit(1);

        }

        ...
    }
}
```



L'ALGORITMO IN JAVA (2/2)

```
...  
float nlati = 4.0F, ln = (float) Math.sqrt(2.0);  
float smpinf, smpsup;  
  
do {  
    float OC2 = (float) Math.sqrt(4.0 - ln * ln);  
    nlati *= 2.0;  
    ln = (float) Math.sqrt(2.0F - OC2);  
    smpinf = ln * nlati / 2.0F;  
    smpsup = ln * nlati / OC2;  
    System.out.println("nl=" + nlati + " d2=" + OC2 +  
        " piInf=" + smpinf + " piSup=" + smpsup);  
} while ((smpsup-smpinf >= eps) && (nlati < 1e+19));  
  
}  
}
```



L'OUTPUT con EPS = 1E-04 (ok)

Calcolo di pigreco con FLOAT.

Precisione (suggerito 1e-8)? 1e-4

n1=8.0	d2=1.4142137	piInf=3.0614672	piSup=4.329568
n1=16.0	d2=1.8477591	piInf=3.1214445	piSup=3.378627
n1=32.0	d2=1.9615706	piInf=3.1365461	piSup=3.1979947
n1=64.0	d2=1.9903694	piInf=3.1403334	piSup=3.155528
n1=128.0	d2=1.9975909	piInf=3.1412857	piSup=3.1450741
n1=256.0	d2=1.9993976	piInf=3.1415188	piSup=3.1424654
n1=512.0	d2=1.9998494	piInf=3.1412080	piSup=3.1414444
n1=1024.0	d2=1.9999623	piInf=3.1424513	piSup=3.1425104

PRIMO COLLAUDO POSITIVO!
quindi va tutto bene.... (forse..)

L'OUTPUT con EPS = 1E-08: ARGH!

Calcolo di pigreco con FLOAT.

Precisione (suggerito 1e-8)? **1e-8**

n1=8.0	d2=1.4142137	piInf=3.0614672	piSup=4.329568
n1=16.0	d2=1.8477591	piInf=3.1214445	piSup=3.378627
n1=32.0	d2=1.9615706	piInf=3.1365461	piSup=3.1979947
n1=64.0	d2=1.9903694	piInf=3.1403334	piSup=3.155528
n1=128.0	d2=1.9975909	piInf=3.1412857	piSup=3.1450741
n1=256.0	d2=1.9990976	piInf=3.1415188	piSup=3.1424654
n1=512.0	d2=1.999494	piInf=3.1412080	piSup=3.1414444
n1=1024.0	d2=1.999523	piInf=3.1424513	piSup=3.1425104
n1=2048.0	d2=1.999906	piInf=3.1424513	piSup=3.142466
n1=4096.0	d2=1.999976	piInf=3.1622777	piSup=3.1622815
n1=8192.0	d2=1.999994	piInf=3.1622777	piSup=3.1622787
n1=16384.0	d2=1.9999999	piInf=2.8284270	piSup=2.8284273
n1=32768.0	d2=2.0	piInf=0.0	piSup=0.0

ORRORE!

ora pigreco = 0 !!




E L'EFFICIENZA?

- Spesso gli algoritmi più «ovvii» per fare un calcolo non sono i più efficienti
 - la matematica del computer non è quella dell'analisi...
 - le funzioni irrazionali e trascendenti sono calcolate con *sviluppi in serie*
- Se l'efficienza è un aspetto chiave, a volte può essere consigliabile *reformulare gli algoritmi*
 - ricorrendo all'aritmetica intera quando possibile
 - oppure, *impostando il problema in un modo diverso*

ESEMPIO: DISEGNARE UNA CIRCONFERENZA

- L'algoritmo più ovvio prevedrebbe l'uso della relazione
$$y = \sqrt{R^2 - x^2}$$
 - *esso però contiene una radice quadrata*
 - con molti punti da calcolare, è assai inefficiente
- Un approccio «smart» alternativo
 - IDEA: calcolare solo un (mezzo) quadrante e ottenere gli altri punti per simmetria
 - ma soprattutto, *sfruttare la derivata* per calcolare «il prossimo punto» *evitando del tutto la radice!*
 - a basso livello (es. assembler), assai scomodo



ESEMPIO: DISEGNARE UNA CIRCONFERENZA

- Infatti, poiché $x = R \cos t$ e $y = R \sin t$,
vale la relazione $\frac{dy}{dx} = -\frac{x}{y}$
- Essa consente facilmente di determinare il punto
adiacente *senza ricorrere ai radicali*
 - si parte da $(0, R)$ e ci si muove solo fino a $(R/2, R/2)$,
per evitare punti a tangente verticale

$$\Delta y = -\frac{x}{y} \Delta x$$

- gli altri 7 pixel si ottengono per simmetria
- fattibile con semplici operazioni aritmetiche
→ adatto anche a basso livello (es. assembler)

